

Datavoorbewerking van mutatie-data

Jalisa Shaline van der Zeeuw

2026-01-01

Methylatie bestand

Het bestand `CCLE_RRBS_TSS1kb_20181022.txt` bevat DNA-methylatiegegevens gemeten rond de Transcription Start Site (TSS, ± 1 kb). Dit gebied omvat zowel promoterregio's als het eerste exon, die belangrijk zijn voor genregulatie.

In dit notebook wordt de DNA-methylatie-data van CCLE voorbereid voor integratie met mutatie- en responsdata. De focus ligt op longkankercellijnen. De preprocessing omvat het verkennen van de datastructuur, het selecteren van relevante cellijnen, kwaliteitscontrole, en het harmoniseren van identifiers zodat de data geschikt is voor verdere analyses en samenvoeging.

Stap 1. Inlezen en verkennen van de methylatie-data

Doel: Het inlezen van de DN-methylatie-data van CCLE en het uitvoeren van een eerste verkenning van de dataset.

We bekijken het aantal rijen/kolommen, de eerste en laatste kolomnamen, datatypes en missing values.

In deze stap wordt inzicht verkregen:

- het aantal rijen en kolommen
- de structuur van de dataset
- de aanwezige metadata
- de manier waarop cellijnen zijn gecodeerd
- en de aanwezigheid van eventuele missende waarden.

De dataset bevat methylatiewaarden per CpG-locus voor een groot aantal kankercellijnen. Het is belangrijk om eerst te begrijpen hoe deze cellijnen worden gerepresenteerd voordat filtering op relevante data wordt toegepast.

Aantal rijen en kolommen: (21338, 846)

Eerste 5 kolommen: ['locus_id', 'CpG_sites_hg19', 'avg_coverage', 'DMS53_LUNG', 'SW1116_LARGE_1']

Laatste 5 kolommen: ['U031_KIDNEY', 'SF268_CENTRAL_NERVOUS_SYSTEM', 'SF539_CENTRAL_NERVOUS_SYSTEM', 'SF539_CENTRAL_NERVOUS_SYSTEM', 'SF539_CENTRAL_NERVOUS_SYSTEM']

	kolom	dtype	n_missing
0	locus_id	object	0
1	CpG_sites_hg19	object	1

2	avg_coverage	object	0
3	DMS53_LUNG	object	0
4	SW1116_LARGE_INTESTINE	object	0
	kolom	dtype	n_missing
841	U031_KIDNEY	object	0
842	SF268_CENTRAL_NERVOUS_SYSTEM	object	0
843	SF539_CENTRAL_NERVOUS_SYSTEM	object	0
844	SNB75_CENTRAL_NERVOUS_SYSTEM	object	0
845	HOP92_LUNG	object	0

Waarnemingen:

- De dataset bevat 21338 rijen, waarbij elke rij een CpG-locus representeert, en 846 kolommen.
- De eerste 3 kolommen bevatten metadata:
 - * **locus_id**: unieke identifier van de CpG-locus
 - * **CpG_sites_hg19**: genoompositie van de locus (hg19 referentie)
 - * **avg_coverage**: gemiddelde sequencingdiepte, een maat voor de betrouwbaarheid van de meting
- De overige 843 kolommen representeren individuele kankercellijnen.
- De cellijnen worden niet weergegeven met een standaard DepMap-identificer (ACH- of ModelID). In plaats daarvan worden cellijnen geïdentificeerd op basis van hun naam, waarbij de kolomtitel zowel de cellijnnaam als het weefseltype bevat (bijvoorbeeld DMS53_LUNG).

Deze verkenning laat zien dat preprocessing nodig is voordat de methylatiedata kan worden samengevoegd met de andere datasets. In de vervolgstappen zullen de longkankercellen worden geselecteerd, zal een kwaliteitscontrole worden uitgevoerd om niet informatieve loci te verwijderen, en zal er een mapping worden toegepast om de cellijnkolommen te harmoniseren naar standaard DepMap-identifiers (ACH_ID/ModelID).

Stap 2. Filteren op longkankercellijnen

Doel: Alleen de kolommen behouden die longkankercellijnen representeren (__LUNG). Zo wordt er een subset aangemaakt van de relevante data.

Probleem: Methylatiebestand heeft geen DepMap- of ACH-ID's, maar gebruikt kolomnamen die bestaan uit cellijnnaam + weefseltype (zoals DMS53_LUNG, SW1116_LARGE_INTESTINE). Elke kolom is een cellijn en elke rij is een methylatie-feature (CpG-site).

In plaats van filteren op rijen, moeten de kolommen worden geselecteerd die bij longkanker horen (dus de kolommen waarvan de naam “_LUNG” bevat. Ter controle worden de eerste 5 rijen van de eerste en laatste kolommen weergegeven.

Aantal longkankercellijnen: 153

Vorm van longkankermethylatie matrix: (21338, 156)

	locus_id	\
0	SGIP1_1_66998638_66999638	
1	SGIP1_1_66998251_66999251	
2	AZIN2_1_33545713_33546713	
3	AZIN2_1_33546778_33547778	
4	AGBL4_1_50489626_50490626	

	CpG_sites_hg19	avg_coverage	DMS53_LUNG	\
0	1:66998970;1:66998973;1:66998993;1:66999404;1:...	25.00	0.00000	
1	1:66998970;1:66998973;1:66998993	8.27	0.00000	
2	1:33546151;1:33546209;1:33546210;1:33546385;1:...	326.58	0.00729	
3	1:33546783;1:33546788;1:33546795;1:33546797;1:...	480.54	0.22276	
4	1:50489632;1:50489641;1:50489671;1:50489677;1:...	263.36	0.00000	

	NCIH1184_LUNG	NCIH2227_LUNG	...	HCC2935_LUNG	LCLC103H_LUNG	LCLC97TM1_LUNG	\
0	0.11864	0.04545	...	NaN	NaN	1.00000	
1	0.22579	NaN	...	NaN	NaN	NaN	
2	0.22553	0.04560	...	0.24294	0.01045	0.03746	
3	0.10735	0.03326	...	0.36441	0.24371	0.23342	
4	0.07346	0.01246	...	0.01515	0.05079	0.86448	

	HOP62_LUNG	EKVX_LUNG	HOP92_LUNG
0	NA	NA	0.66667
1	NA	NA	0.66667
2	NA	NA	0.00046
3	NA	NA	0.05159
4	NA	NA	0.54553

[5 rows x 156 columns]

Waarnemingen:

- na filtering op kolomnamen die _LUNG bevatten zijn 153 longkankercellijnen geselecteerd.
- de resulterende matrix bevat 21338 CpG-loci (rijen) en 156 kolommen, bestaande uit:
- 3 metadata kolommen (locus_id, CpG_sites_hg19, avg_coverage)
- 153 kolommen met methylatiewaarden voor longkankercellijnen.
- de aanwezigheid van NaN-waarden in sommige cellijnkolommen wijst op ontbrekende methylatiemetingen. Dit zal later worden meegenomen in de kwaliteitscontrole.

De filtering op longkankercellijnen is succesvol toegepast en vormt de basis voor verdere kwaliteitscontrole.

Stap 3. Quality Control (QC)

Doel: Het verbeteren van de betrouwbaarheid van de methylatie data door het verwijderen van CpG-loci met onbetrouwbare metingen of onvoldoende informatiedichtheid.

DNA-methylatiedata bevat vaak ruis als gevolg van lage sequencingdiepte, ontbrekende waarden of loci die in slechts een beperkt aantal cellijnen gemeten zijn. Deze loci verstoren de analyse en kunnen leiden tot instabiele schattingen en een vertekend beeld van de methylatiepatronen.

Daarom wordt in deze stap een reeks kwaliteitscontroles uitgevoerd, waarbij CpG-loci stapsgewijs wordt gefilterd op basis van:

- meetbetrouwbaarheid (coverage)
- mate van ontbrekende waarden
- en variatie over cellijnen

Coverage Filtering: rijen met lage avg_coverage verwijderen

Doel:

Bij methylatie-metingen varieert de meetdiepte (`avg_coverage`) per CpG-locus. Loci met lage coverage kunnen onbetrouwbare methylatiewaarden bevatten en dragen bij aan ruis in downstream analyses. Door te filteren op coverage worden alleen loci behouden met voldoende meetbetrouwbaarheid.

Aanpak: De kolom `avg_coverage` wordt vanuit het tekstbestand ingelezen als string, terwijl het in werkelijkheid een getal is. Om er mee te kunnen rekenen of filteren, moet de kolom worden omgezet naar een numeriek datatype.

Sommige loci kunnen een ontbrekende of ongeldige coveragewaarde (NaN) hebben. Voor deze loci is het niet mogelijk om de betrouwbaarheid van de meting te beoordelen. Deze rijen leveren geen bruikbare informatie op en worden daarom verwijderd.

Vervolgens worden alleen loci behouden met een `avg_coverage` ≥ 10 . [bron](#)

Aantal loci voor filtering op avg coverage: 21338

Aantal loci na coverage filtering: 20898

Er zijn slechts een beperkt aantal loci verwijderd. Dit geeft aan dat het merendeel van de CpG-loci met voldoende sequencingdiepte is gemeten. Het resultaat is een subset van CpG-loci die kwalitatief sterk genoeg is voor downstream analyse.

Missingness: rijen met teveel ontbrekende waarden verwijderen

Doel: Het verwijderen van CpG-loci die in een groot deel van de longkankercellijnen niet gemeten zijn.

Loci met veel ontbrekende waarden leveren geen consistente informatie.

Aanpak:

Voor elke locus wordt het percentage ontbrekende waarden berekend over alle longkankercellijnen. Loci met meer dan 10% ontbrekende waarden worden verwijderd. Deze drempel is relatief streng en zorgt ervoor dat de overgebleven loci in vrijwel alle cellijnen beschikbaar zijn, wat de betrouwbaarheid van downstream analyses vergroot.

Loci vóór missingness filtering: 20898

Loci na missingness filtering: 18449

Verwijderd door missingness: 2449

Na missingness filtering is ongeveer 12% van de loci is verwijderd.

Variance Filtering

Doel:

Het verwijderen van CpG-loci die weinig variatie laten zien over de longkankercellijnen.

Voorafgaand aan het trainen van het Random Forest-model is variance filtering toegepast om loci met vrijwel constante methylatiewaarden te verwijderen. Per locus is de variatie over alle longkankercellijnen berekend. Loci met een lage variatie dragen weinig bij aan het onderscheiden van cellijnen en kunnen alleen maar ruis introduceren.

In deze analyse is per locus de standaarddeviatie (std) berekend, waarna loci met $\text{std} < 0.05$ zijn verwijderd. Deze drempel wordt veelgebruikt in methylatie-studies om niet-informatieve CpG-loci te verwijderen. Technisch wordt dit vertaald naar variance, waarbij $\text{std} = 0.05$ overeenkomt met een variance threshold van 0.0025.

Loci vóór variance filtering: 18449

Loci na variance filtering: 10667

Verwijderd door lage variantie: 7782

Na toepassing van variance filtering ($\text{std} = 0.05$ / $\text{variance} = 0.0025$) zijn ongeveer 42% van de loci verwijderd vanwege onvoldoende variatie. Dit is normaal aangezien methylatieprofielen vaak veel CpG-loci bevatten die weinig variatie vertonen [Meng et al., 2010].

Stap 4. Mapping en transponeren van de methylatie-data

Doel: Methylatie-data voorbereiden op integratie met de andere datasets (mutaties en responswaarden).

Daarvoor moeten we de cellijnnamen in de methylatie-dataset eerst worden vertaald naar hun bijbehorende DepMap/ACH-IDs, zodat alle bestanden een gedeelde unieke identifier gebruiken. Vervolgens wordt de dataset getransponeerd zodat cellijnen rijen worden en loci kolommen, wat het juiste formaat is voor downstream analyse en modelbouw.

Aanpak:

- Metadata inladen: De DepMap-annotatie bevat de koppeling tussen CCLE-namen (zoals DMS53_LUNG) en de standaard DepMap/ACH-IDs. Deze dataset wordt ingeladen en beperkt tot de kolommen die nodig zijn voor mapping: `CCLE_ID` → `DepMapID`.
- Mapping uitvoeren: De methylatiekolommen worden gematcht op de CCLE-celnamen, die via DepMap-annotatie worden gekoppeld aan hun bijbehorende ACH-IDs. Alleen cellijnen waarvoor een geldige DepMap-ID bestaat, worden behouden.
- Transponeren van de dataset: Na de mapping wordt het DataFrame omgezet zodat de ACH-IDs de tijen vormen en de methylatie-loci de kolommen. Dit formaat sluit aan bij de andere datasets en maakt latere merge-stappen eenvoudig.

Output:

Metadata ingeladen.

Aantal rijen en kolommen: (1461, 33)

Beschikbare belangrijke kolommen:

```
['CCLE_ID', 'depMapID', 'Name', 'Site_Primary', 'Site_Subtype1', 'Site_Subtype2', 'Site_Subtype3']
```

Aantal cellijnen bruikbaar voor mapping: 1457

Aantal cellijnen na mapping: 153

Transponeren voltooid.

Vorm van de getransponeerde methylatie-matrix: (153, 10667)

locus_id	AZIN2_1_33545713_33546713	AZIN2_1_33546778_33547778	AGBL4_1_50489626_50490626
ModelID			
ACH-000698	0.00729	0.22276	0.00000
ACH-000523	0.22553	0.10735	0.07346
ACH-000610	0.04560	0.03326	0.01246
ACH-000774	0.14577	0.09589	0.00531
ACH-000875	0.11487	0.21004	0.07422

Resultaat van de methylatie-matrix

Ter controle zijn de eerste rijen van de getransponeerde methylatiematrix weergegeven. Elke rij representeert één cellijn, geïdentificeerd door een `ModelID` (ACH-ID). De kolommen vertegenwoordigen individuele CpG-loci. De CpG-loci volgen de standaard DepMap-namingconventie `GENE_CHROM_START_ENG`, die aangeeft bij welk gen de tile hoort en op welke genomische coördinaten deze is gebaseerd.

De matrix heeft het juiste formaat voor verdere analyses: cellijnen als rijen en methylatiefeatures als kolommen. Deze opgeschoonde, gefilterde en gemapte methylatiematrix wordt opgeslagen en later gebruikt in `dv1_dataprep.ipynb` voor het beantwoorden van deelvraag 1.