

dataprep_methylation

December 4, 2025

Methylatie bestand

CCLE_RRBS_TSS1kb_20181022.txt - bevat DNA-methylatiegegevens gemeten rond de Transcription Start Site (TSS, ± 1 kb). Dit gebied omvat zowel promoterregio's als het eerste exon, die belangrijk zijn voor genregulatie.

Stap 1. Inlezen en verkennen van de methylatie-data

Doel: de methylatie-data van CCLE inlezen en een eerste verkenning doen.

We bekijken het aantal rijen/kolommen, de eerste en laatste kolomnamen, datatypes en missing values.

Omdat we alleen methylatie van longkankercellijnen willen analyseren selecteren we de kolommen waarvan de naam `_LUNG` bevat. Het resultaat is een dataframe met: - Metadata (`locus_id`, `CpG_sites_Hg19`, `avg_coverage` - Akkeen de cellijnkolommen die longkanker representeren

```
The history saving thread hit an unexpected error (OperationalError('attempt to write a readonly database')).History will not be written to the database.
```

```
Aantal rijen en kolommen: (21338, 846)
```

```
Eerste 5 kolommen: ['locus_id', 'CpG_sites_hg19', 'avg_coverage', 'DMS53_LUNG', 'SW1116_LARGE_INTESTINE']
```

```
Laatste 5 kolommen: ['U031_KIDNEY', 'SF268_CENTRAL_NERVOUS_SYSTEM', 'SF539_CENTRAL_NERVOUS_SYSTEM', 'SNB75_CENTRAL_NERVOUS_SYSTEM', 'HOP92_LUNG']
```

	kolom	dtype	n_missing
0	locus_id	object	0
1	CpG_sites_hg19	object	1
2	avg_coverage	object	0
3	DMS53_LUNG	object	0
4	SW1116_LARGE_INTESTINE	object	0

	kolom	dtype	n_missing
841	U031_KIDNEY	object	0
842	SF268_CENTRAL_NERVOUS_SYSTEM	object	0
843	SF539_CENTRAL_NERVOUS_SYSTEM	object	0
844	SNB75_CENTRAL_NERVOUS_SYSTEM	object	0
845	HOP92_LUNG	object	0

Waarneming:

- De dataset bevat 21338 rijen die CpG-loci representeren en 846 kolommen.
- De eerste 3 kolommen zijn metadata:

- locus_id: unieke identifier van de CpG-locus
 - CpG_sites_hg19:genoompositie van de locus
 - avg_coverage: gemiddelde meetdiepte, een maat voor de betrouwbaarheid van de meting
- De overige 843 kolommen zijn de cellijnen.
 - Wat me opvalt is dat dit bestand geen ACH- of ModelID bevat. In plaats daarvan worden cellijnen geïdentificeerd op basis van hun naam, waarbij de kolomtitel zowel de cellijnnaam als het weefseltype bevat (bijvoorbeeld DMS53_LUNG).

Om uiteindelijk 3 datasets samen te voegen zal een mapping moeten worden uitgevoerd van deze kolomnamen naar de bijbehorende ACH_ID.

Stap 2. Filteren op lonkankercellijnen

Doel: Alleen de kolommen behouden die lonkankercellijnen representeren (_LUNG). Zo wordt er een subset aangemaakt van de relevante data.

Aantal lonkankercellijnen: 153

Vorm van longkankermethylatie matrix: (21338, 156)

	locus_id \				
0	SGIP1_1_66998638_66999638				
1	SGIP1_1_66998251_66999251				
2	AZIN2_1_33545713_33546713				
3	AZIN2_1_33546778_33547778				
4	AGBL4_1_50489626_50490626				

	CpG_sites_hg19	avg_coverage	DMS53_LUNG \
0	1:66998970;1:66998973;1:66998993;1:66999404;1:...	25.00	0.00000
1	1:66998970;1:66998973;1:66998993	8.27	0.00000
2	1:33546151;1:33546209;1:33546210;1:33546385;1:...	326.58	0.00729
3	1:33546783;1:33546788;1:33546795;1:33546797;1:...	480.54	0.22276
4	1:50489632;1:50489641;1:50489671;1:50489677;1:...	263.36	0.00000

	NCIH1184_LUNG	NCIH2227_LUNG	RERFLCAD2_LUNG	NCIH2347_LUNG	NCIH2087_LUNG \
0	0.11864	0.04545	NaN	0.25000	0.86441
1	0.22579	NaN	NaN	NaN	0.97871
2	0.22553	0.04560	0.14577	0.11487	0.17708
3	0.10735	0.03326	0.09589	0.21004	0.35571
4	0.07346	0.01246	0.00531	0.07422	0.60335

	NCIH2085_LUNG	...	NCIH1944_LUNG	NCIH2405_LUNG	BEN_LUNG	NCIH727_LUNG \
0	1.00000	...	0.10344	NaN	0.90907	NaN
1	NaN	...	0.11110	NaN	NaN	NaN
2	0.15413	...	0.02693	0.00697	0.07692	0.05825
3	0.03926	...	0.04961	0.00380	0.01200	0.12764
4	0.00000	...	0.00130	0.11082	0.01485	0.10371

	HCC2935_LUNG	LCLC103H_LUNG	LCLC97TM1_LUNG	HOP62_LUNG	EKVX_LUNG	HOP92_LUNG
0	NaN	NaN	1.00000	NA	NA	0.66667
1	NaN	NaN	NaN	NA	NA	0.66667
2	0.24294	0.01045	0.03746	NA	NA	0.00046
3	0.36441	0.24371	0.23342	NA	NA	0.05159
4	0.01515	0.05079	0.86448	NA	NA	0.54553

[5 rows x 156 columns]

Stap 3. Quality Control (QC)

Er worden een aantal stappen uitgevoerd om de dataset betrouwbaar, schoon en geschikt te maken voor analyse.

(...eventueel stappen benoemen...)

Coverage Filtering: rijen met lage avg_coverage verwijderen Doel:

Bij methylatie-metingen varieert de meetdiepte (avg_coverage) per CpG-locus. Lage coverage kan leiden tot onbetrouwbare waarden en ruis in downstream analyses. Daarom worden loci met lage gemiddelde coverage weggefilterd, zodat alleen loci met voldoende betrouwbare metingen overblijven.

Aanpak: De kolom avg_coverage wordt vanuit het tekstbestand ingelezen als string, terwijl het in werkelijkheid een getal is. Om er mee te kunnen rekenen of filteren, moet de kolom worden omgezet naar een numeriek datatype.

Sommige loci kunnen een ontbrekende of ongeldige coveragewaarde (NaN) hebben. Voor deze loci is het onmogelijk om te betrouwbaarheid van de meting te beoordelen. Deze rijen leveren geen bruikbare informatie op en worden daarom verwijderd.

Vervolgens worden alleen loci behouden met een avg_coverage > 10. Loci met lage coverage bevatten ruis en onbetrouwbare methylatiewaarden. Door

Het resultaat is een subset van CpG-loci die kwalitatief sterk genoeg is voor downstream analyse.

Aantal loci voor filtering op avg coverage: 21338

Aantal loci na coverage filtering: 20898

Missingness: rijen met teveel ontbrekende waarden verwijderen Doel: Verwijderen van CpG-loci die te veel ontbrekende methylatiewaarden hebben over longkankercellijnen. Dit vermindert ruis en zorgt dat downstream analyses betrouwbaarder zijn.

Aanpak:

Voor elke locus wordt het percentage ontbrekende waarden berekend. Loci met meer dan 10% missende waarden worden verwijderd. Deze drempel is relatief streng en zorgt ervoor dat de overgebleven loci bijna overal gemeten zijn, wat de kwaliteit van de dataset verhoogd.

Loci vóór missingness filtering: 20898

Loci na missingness filtering: 18449

Verwijderd door missingness: 2449

```

/var/folders/hf/q9gpk8mn1l34cwvqff64g18c0000gn/T/ipykernel_54316/1362123296.py:1
2: PerformanceWarning: DataFrame is highly fragmented. This is usually the
result of calling `frame.insert` many times, which has poor performance.
Consider joining all columns at once using pd.concat(axis=1) instead. To get a
de-fragmented frame, use `newframe = frame.copy()`
lung_methylation_qc['missing_fraction'] =
lung_methylation_qc[methylation_cols].isna().mean(axis=1)

```

De overgebleven loci zijn betrouwbaar gemeten in het merendeel van de cellijnen en vormen een goede basis voor de volgende QC-stap. Ongeveer 12% van de loci is verwijderd wat betekent dat de dataset aanzienlijk is schoongemaakt van ruis zonder te veel relevante informatie te verliezen.

Variance Filtering Doel:

Het verwijderen van CpG-loci die weinig variatie laten zien over de longkankercellijnen.

Loci met bijna constante methylatiewaarden dragen weinig bij aan downstream analyses en kunnen ruis toevoegen.

Aanpak: Eerst wordt de standaarddeviatie (std) per locus over alle longkankercellijnen berekend. Er wordt een drempel ingesteld waarmee loci met $\text{std} < 0.05$ worden verwijderd. Deze drempel is gangbaar in methylatieonderzoek waarbij loci met $\text{std} \geq 0.05$ voldoende variatie laten zien en als informatief worden beschouwd.

Vervolgens moet er een drempel worden ingesteld waarbij loci met variantie lager dan een gekozen waarde worden verwijderd.

```

Loci vóór variance filtering: 18449
Loci na variance filtering: 4569
Verwijderd door lage variantie: 13880

```

Ongeveer 75% van de loci vertoonde te weinig variatie en zijn verwijderd, wat normaal is bij genome-wide methylatie-data, aangezien veel CpG-loci vrijwel constant of weinig variabel zijn over de cellijnen.

Stap 4. Mapping en transponeren van de methylatie-data

Doel: Methylatie-data voorbereiden op integratie met de andere datasets (mutaties en responswaarden).

Daarvoor moeten we de cellijnnamen in de methylatie-dataset eerst worden vertaald naar hun bijbehorende DepMap/ACH-IDs, zodat alle bestanden een gedeelde unieke identifier gebruiken. Vervolgens wordt de dataset getransponeerd zodat cellijnen rijen worden en loci kolommen, wat het juiste formaat is voor downstream analyse en modelbouw.

Aanpak:

- Metadata inladen: De DepMap-annotatie bevat de koppeling tussen CCLE-namen (zoals DMS53_LUNG) en de standaard DepMap/ACH-IDs. Deze dataset wordt ingeladen en beperkt tot de kolommen die nodig zijn voor mapping: `CCLE_ID -> DepMapID`.
- Mapping uitvoeren: De methylatiekolommen worden vergeleken met de CCLE-IDs in de metadata. Alleen cellijnen waarvoor een geldige DepMap-ID bestaat, worden behouden. De kolomnamen worden vervangen door ACH-IDs.

- Transponeren van de dataset: Na de mapping wordt het DataFrame omgezet zodat de ACH-IDs de tijen vormen en de methylatie-loci de kolommen. Dit formaat sluit aan bij de andere datasets en maakt latere merge-stappen eenvoudig.

Metadata ingeladen.

Aantal rijen en kolommen: (1461, 33)

Beschikbare belangrijke kolommen:

```
['CCLE_ID', 'depMapID', 'Name', 'Site_Primary', 'Site_Subtype1',
'Site_Subtype2', 'Site_Subtype3', 'Disease']
```

Aantal cellijnen bruikbaar voor mapping: 1457

Aantal cellijnen na mapping: 153

Transponeren voltooid.

Vorm van de getransponeerde methylatie-matrix: (153, 4569)

locus_id	AGBL4_1_50489626_50490626	SLC45A1_1_8377144_8378144	\
ModelID			
ACH-000698	0.00000	0.06154	
ACH-000523	0.07346	0.04211	
ACH-000610	0.01246	0.40403	
ACH-000774	0.00531	0.18182	
ACH-000875	0.07422	0.15942	

locus_id	TGFBR3_1_92351836_92352836	PRKCZ_1_2004424_2005424	\
ModelID			
ACH-000698	0.06495	0.90697	
ACH-000523	0.12579	0.17693	
ACH-000610	0.06295	0.20561	
ACH-000774	0.09434	0.84290	
ACH-000875	0.11582	0.94621	

locus_id	PRDM16_1_2984741_2985741	KAZN-AS1_1_14746469_14747469	\
ModelID			
ACH-000698	0.05687	0.03296	
ACH-000523	0.02214	0.20000	
ACH-000610	0.00902	0.85541	
ACH-000774	0.06143	0.36966	
ACH-000875	0.15642	0.41465	

locus_id	CSMD2_1_34631443_34632443	RNF220_1_44888495_44889495	\
ModelID			
ACH-000698	0.08394	0.86905	
ACH-000523	0.19928	0.23962	
ACH-000610	0.08861	0.58460	
ACH-000774	0.12902	0.30636	
ACH-000875	0.79630	0.02632	

locus_id	SCP2_1_53391900_53392900	DAB1_1_57888784_57889784	...	\
ModelID			...	
ACH-000698	0.10964	0.00000	...	
ACH-000523	0.37374	0.02541	...	
ACH-000610	0.15685	0.01953	...	
ACH-000774	0.20237	0.02556	...	
ACH-000875	0.31252	0.24499	...	

locus_id	RIBC2_22_45808571_45809571	FBLN1_22_45897718_45898718	\
ModelID			
ACH-000698	0.00529	0.02528	
ACH-000523	0.97040	0.19720	
ACH-000610	0.75786	0.10829	
ACH-000774	0.56134	0.06710	
ACH-000875	0.01204	0.37677	

locus_id	MIR3619_22_46485923_46486923	MIRLET7BHG_22_46480876_46481876	\
ModelID			
ACH-000698	0.97458	0.92657	
ACH-000523	0.95495	0.82109	
ACH-000610	0.44571	0.44586	
ACH-000774	0.79487	0.15264	
ACH-000875	1.00000	0.52817	

locus_id	LINC00899_22_46440748_46441748	LINC00898_22_48027318_48028318	\
ModelID			
ACH-000698	0.00000	0.00000	
ACH-000523	0.17443	0.35302	
ACH-000610	0.30959	0.42902	
ACH-000774	0.60137	0.21231	
ACH-000875	0.01380	0.48066	

locus_id	LOC284933_22_48943199_48944199	MIR4535_22_49175106_49176106	\
ModelID			
ACH-000698	0.00000	0.00277	
ACH-000523	0.18813	0.20239	
ACH-000610	0.44565	0.39904	
ACH-000774	0.73684	0.43176	
ACH-000875	0.90804	0.40959	

locus_id	IL17REL_22_50451055_50452055	TRABD_22_50627978_50628978
ModelID		
ACH-000698	0.35996	0.89704
ACH-000523	0.82296	0.81493
ACH-000610	0.35151	0.45146
ACH-000774	0.26277	0.50296

ACH-000875

0.31794

0.31934

[5 rows x 4569 columns]

Resultaat van de methylatie-matrix

Ter controle zijn de eerste rijen van de getransponeerde methylatiematrix weergegeven. De eerste kolom bevat de `ModelID`, waarbij elke rij overeenkomt met één cellijn (ACH-ID). Alle overige kolommen vertegenwoordigen individuele CpG-loci. Deze loci hebben een standaard DepMap-namingconventie `GENE_CHROM_START_END`, wat aangeeft bij welk gen de tile hoort en op welke genomische coördinaten deze is gebaseerd.

De methylatie-matrix heeft daarmee het juiste formaat voor verdere analyses: cellijnen als rijen en methylatiefeatures als kolommen. Deze opgeschoonde en gemapte methylatiematrix wordt later gebruikt in het final/merge-notebook voor deelvraag 1, waar alle datasets worden gecombineerd tot één dataset.