

dataprep_mutation

December 12, 2025

Stap 1. Inlezen en verkennen van de mutatie-data Doel: de mutatie-data van CCLE inlezen en een eerste verkenning doen.

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 751310 entries, 0 to 751309
```

```
Data columns (total 70 columns):
```

#	Column	Non-Null Count	Dtype
0	Chrom	751310 non-null	object
1	Pos	751310 non-null	int64
2	Ref	751310 non-null	object
3	Alt	751310 non-null	object
4	AF	751310 non-null	float64
5	DP	751310 non-null	int64
6	RefCount	751310 non-null	int64
7	AltCount	751310 non-null	int64
8	GT	751310 non-null	object
9	PS	44923 non-null	float64
10	VariantType	751310 non-null	object
11	VariantInfo	751310 non-null	object
12	DNAChange	750960 non-null	object
13	ProteinChange	726857 non-null	object
14	HugoSymbol	751310 non-null	object
15	Exon	728937 non-null	object
16	Intron	23986 non-null	object
17	EnsemblGeneID	751310 non-null	object
18	EnsemblFeatureID	751310 non-null	object
19	HgncName	734284 non-null	object
20	HgncFamily	531438 non-null	object
21	UniprotID	433949 non-null	object
22	DbsnpRsID	12007 non-null	object
23	GcContent	751310 non-null	float64
24	LofGeneName	102748 non-null	object
25	LofGeneId	102748 non-null	object
26	LofNumberOfTranscriptsInGene	102748 non-null	float64
27	LofPercentOfTranscriptsAffected	102748 non-null	float64
28	NMD	30606 non-null	object
29	MolecularConsequence	25215 non-null	object
30	VepImpact	751310 non-null	object

31	VepBiotype	751310 non-null	object
32	VepHgnCID	751294 non-null	object
33	VepExistingVariation	397193 non-null	object
34	VepManeSelect	735516 non-null	object
35	VepENSP	749044 non-null	object
36	VepSwissprot	693449 non-null	object
37	Sift	599796 non-null	object
38	Polyphen	577290 non-null	object
39	GnomadeAF	751310 non-null	float64
40	GnomadgAF	751310 non-null	float64
41	VepClinSig	27442 non-null	object
42	VepSomatic	254466 non-null	object
43	VepPliGeneValue	664121 non-null	float64
44	VepLofTool	562587 non-null	float64
45	OncogeneHighImpact	751310 non-null	bool
46	TumorSuppressorHighImpact	751310 non-null	bool
47	TranscriptLikelyLof	63420 non-null	object
48	BrcalFuncScore	22 non-null	float64
49	CivicID	1381 non-null	float64
50	CivicDescription	728 non-null	object
51	CivicScore	1381 non-null	float64
52	LikelyLoF	751310 non-null	bool
53	HessDriver	751310 non-null	bool
54	HessSignature	2393 non-null	object
55	RevelScore	574655 non-null	float64
56	PharmgkbId	19 non-null	object
57	DidaID	11 non-null	object
58	DidaName	11 non-null	object
59	GwasDisease	257 non-null	object
60	GwasPmID	257 non-null	float64
61	GtexGene	7 non-null	object
62	ProveanPrediction	558282 non-null	object
63	AMClass	524520 non-null	object
64	AMPathogenicity	524520 non-null	float64
65	Rescue	751310 non-null	bool
66	RescueReason	18617 non-null	object
67	ModelID	751310 non-null	object
68	Hotspot	751310 non-null	bool
69	EntrezGeneID	744341 non-null	float64

dtypes: bool(6), float64(16), int64(4), object(44)

memory usage: 371.1+ MB

	Chrom	Pos	Ref	Alt	AF	DP	RefCount	AltCount	GT	PS	...	\
0	chr1	818203	G	A	0.240	27	21	6	0/1	NaN	...	
1	chr1	851926	G	A	0.158	17	15	2	0/1	NaN	...	
2	chr1	918916	CTGA	C	0.462	51	28	23	0/1	NaN	...	
3	chr1	924510	GC	AA	0.412	35	21	14	0 1	924510.0	...	
4	chr1	924657	C	G	0.437	17	9	8	0/1	NaN	...	

	GwasPmID	GtexGene	ProveanPrediction	AMClass	AMPathogenicity	Rescue	\
0	NaN	NaN	NaN	NaN	NaN	False	
1	NaN	NaN	NaN	NaN	NaN	False	
2	NaN	NaN	NaN	NaN	NaN	False	
3	NaN	NaN	NaN	NaN	NaN	False	
4	NaN	NaN	NaN	NaN	NaN	False	

	RescueReason	ModelID	Hotspot	EntrezGeneID
0	NaN	ACH-000062	False	400728.0
1	NaN	ACH-001949	False	643837.0
2	NaN	ACH-002059	False	100130417.0
3	NaN	ACH-000402	False	148398.0
4	NaN	ACH-000693	False	148398.0

[5 rows x 70 columns]

De mutatie-dataset bevat 751310 rijen en 70 kolommen en bestaat uit de volgende datatypen:

- object: tekst/categorieën (bijvoorbeeld genen en mutatietypes)
- float64: decimale waarden
- bool: waar/onwaar waarden (True/False)
- int64: hele getallen (bijvoorbeeld aantallen mutaties)

Belangrijk voor dit onderzoek:

ModelID: koppeling tussen datasets.

HugoSymbol/EnsemblGeneID: gen waarin mutatie voorkomt.

VariantType: type mutatie (feature voor ML).

DNACChange/ProteinChange: optioneel voor interpretatie.

AF, RefCount, AltCount: betrouwbaarheid / filteren.

LikelyLoF, OncogeneHighImpact, TumorSuppressorHighImpact: impact op functie/belangrijke features.

Sift, Polyphen, RevelScore: schadelijkheidsvoorspelling.

PrimaryDisease/Tissue: filteren op longkankercellijnen.

Stap 2. Filteren op relevante data Doel: alleen de biologische en analyse-relevante mutaties behouden, zodat de dataset overzichtelijk blijft en rekentijd beperkt blijft.

Acties: 1. Filteren op cellijntype: alleen cellijnen van het weefseltype “lung” worden behouden. 2. Filteren op relevante mutaties: niet alle mutaties zijn biologisch significant (veel varianten zijn neutraal of technisch artefact). Daarom worden alleen functionele mutaties behouden op basis van de volgende kolommen: - LikelyLoF (verlies-van-functie mutaties) - OncogeneHighImpact (activerende mutaties in oncogenen) - TumorSuppressorHighImpact (verlies-van-remfunctie in tumorsuppressorgen) - Hotspot (bekende activerende hotspot-mutaties) - HessDriver (mutaties geïdentificeerd als drivers)

Een mutatie wordt behouden als één of meer van deze criteria waar zijn.

Aantal rijen in originele mutatie_df: 751310

Aantal unieke cellijnen in originele mutatie_df: 1939

Aantal rijen na filtering: 12630

Aantal unieke cellijnen: 174

Stap 3. Quality control / opschonen **Doel:** Zorg dat de dataset geschikt is voor machine learning

Acties: 1. Verwijder genen die in alle cellijnen geen mutaties hebben (alleen 0). 2. Controleer dat alle cellijnen en genen uniek zijn, zonder duplicaten. 3. Controleer op ontbrekende waarden: - NaN betekent meestal geen mutatie → invullen met 0.

Echte ontbrekende waarden vóór filtering:

- Ontbrekende ModelID: 0
- Ontbrekende genen (HugoSymbol): 0

Aantal cellijnen: 174

Aantal genen: 7358

Aantal mutaties in dataset: 12630

Totaal mogelijke combinaties (cellijnen x genen): 1280292

Percentage mutaties aanwezig: 0.99%

De overige combinaties zijn geen mutaties, wat biologisch correct is.

Aantal ontbrekende waarden in pivot vóór invullen: 1267889

Deze NaN's vertegenwoordigen cellijn-gen combinaties zonder geregistreeerde mutaties.

Aantal ontbrekende waarden na invullen: 0

In de originele dataset zijn geen echte ontbrekende waarden aanwezig in de sleutelkolommen (ModelID en HugoSymbol). In de pivotmatrix ontstaan veel NaN's omdat alleen combinaties met geregistreeerde mutaties een waarde hebben. Deze NaN's zijn ingevuld met 0 voor de definitieve binaire matrix, wat aangeeft dat het gen in die cellijn geen relevante mutatie bevat. Het lage percentage mutaties (~0.99%) is biologisch consistent met wat wordt verwacht in longkankercellijnen en draagt daarmee bij aan de betrouwbaarheid.

Stap 4. Transformatie naar binaire matrix **Doel:** De dataset geschikt maken voor machine learning: - rijen = cellijnen - kolommen = genen - waarden = 0/1 (binair)

Acties: - Voor elke cellijn (ModelID) en gen (HugoSymbol): - 1 als minstens één relevante mutatie aanwezig is - 0 als geen mutatie aanwezig is

(174, 7358)

HugoSymbol	A1CF	A2M	A2ML1	A4GALT	AAAS
ModelID					
ACH-000012	0	0	0	0	0
ACH-000015	0	0	0	0	0
ACH-000021	0	0	0	0	0
ACH-000029	0	0	0	0	0
ACH-000030	0	0	0	0	0