

Datavoorbewerking van responsdata

Jalisa Shaline van der Zeeuw

2026-01-01

Responsdata Preprocessing

In dit notebook wordt de responsdata voorbereid voor integratie met de mutatie- en methylatiematrixes.

Drug_sensitivity_AUC_(PRISM_Repurposing_Secondary_Screen)_subsetting.csv - bevat therapieresponsgegevens (AUC-waarden) die aangeven hoe gevoelig een cellijn is voor een bepaald medicijn.

[extra uitleg over AUC, nog visueel maken]

Preprocessing bestaat uit: - selectie van relevante cellijnen (longkanker) - selectie van relevante kolommen ('ModelID + AUC-waarden) - harmonisatie van identifiers - kwaliteitscontrole - en het opslaan van de uiteindelijke responsmatrix

Stap 1. Inlezen en verkennen van de responswaarden-data

Doel: Het inlezen van de ruwe responsdata, en een eerste verkenning van de vorm en beschikbare kolommen.

Aantal rijen en kolommen: (480, 1457)

		kolom	dtype	n_missing
0		depmap_id	object	0
1		cell_line_display_name	object	0
2		lineage_1	object	0
3		lineage_2	object	0
4		lineage_3	object	0
5		lineage_6	object	436
6		lineage_4	float64	480
7	8-BROMO-CGMP (BRD:BRD-A00077618-236-07-6)		float64	370
8	NORETYNODREL (BRD:BRD-A00758722-001-04-9)		float64	98
9	PREDNISOLONE-ACETATE (BRD:BRD-A01643550-001-04-9)		float64	432
		kolom	dtype	n_missing
1455	TYLOXAPOL (BRD:BRD-U25960968-000-01-9)		float64	386
1456	SEVELAMER (BRD:BRD-U45393375-000-01-6)		float64	463
	depmap_id cell_line_display_name		lineage_1 \	

0	ACH-000973	639V	Bladder/Urinary Tract
1	ACH-001016	BECKER	CNS/Brain
2	ACH-000927	BT474	Breast
3	ACH-000288	BT549	Breast
4	ACH-000212	CAL120	Breast

	lineage_2	lineage_3	\
0	Urethral Cancer	Urethral Urothelial Carcinoma	
1	Diffuse Glioma	Astrocytoma	
2	Invasive Breast Carcinoma	Breast Invasive Ductal Carcinoma	
3	Invasive Breast Carcinoma	Breast Invasive Carcinoma, NOS	
4	Invasive Breast Carcinoma	Invasive Breast Carcinoma	

	lineage_6	lineage_4	8-BROMO-CGMP (BRD:BRD-A00077618-236-07-6)	\
0	NaN	NaN		0.887284
1	NaN	NaN		0.932656
2	ER+, PR+, HER2+	NaN		NaN
3	Basal B TNBC	NaN		NaN
4	Basal B TNBC	NaN		NaN

	NORETYNODREL (BRD:BRD-A00758722-001-04-9)	\
0		0.870060
1		0.950242
2		0.874661
3		0.974322
4		NaN

	PREDNISOLONE-ACETATE (BRD:BRD-A01643550-001-04-9)
0	NaN
1	NaN
2	NaN
3	NaN
4	NaN

De response-dataset bevat 480 rijen waarbij elke rij een unieke cellijn representeert, en 1457 kolommen. De eerste kolommen bevatten meta-data over de cellijnen:

- `depmap_id`: unieke ID voor elke cellijn (bijvoorbeeld ACH-000973)
- `cell_line_display_name`: leesbare naam van de cellijn (bijvoorbeeld 639V of BECKER)
- `lineage_1` t/m `lineage_6`: beschrijving van de biologische afkomst van de cellijn, van breed tot specifiek.

Vanaf kolom 8 bevatten de overige kolommen de drug-response waarden voor verschillende geneesmiddelen, weergegeven als numerieke scores (AUC). Elke cellijn is getest voor meerdere geneesmiddelen, waarbij sommige waarden ontbreken (NaN).

Stap 2. Filteren op relevante data

Doel: Alleen longkankercellijnen behouden en relevante kolommen selecteren. Alle andere metadata kolommen worden verwijderd om een compacte matrix te creëren.

Aanpak: Dit wordt gedaan door eerst te filteren op de kolom `lineage_1 == "Lung"`. Vervolgens selecteren van de kolom `depmap_id` (later hernoemd naar `ModelID`) en alle kolommen met geneesmiddel-responswaarden (AUC). De overige metadata kolommen worden verwijderd. (`cell_line_display_name`, `lineage_2` t/m `lineage_6`)

Aantal longkankercellijnen: 93

Aantal geneesmiddelen (AUC-kolommen): 1450

	depmap_id	8-BROMO-CGMP (BRD:BRD-A00077618-236-07-6)	NORETYNODREL (BRD:BRD-A007
15	ACH-000840	NaN	0.986123
30	ACH-000921	NaN	0.913647
89	ACH-000454	NaN	0.934788
92	ACH-000868	NaN	0.790187
93	ACH-000901	NaN	0.921198

Stap 3. Controle op missing values

Doel: Zorgen dat de responsmatrix volledig bruikbaar is voor modeltraining.

Omdat het hier om de outputvariabele (AUC) gaat, mogen er geen missende waarden zijn. Elke missende waarde betekent dus dat die hele rij (cellijn) of kolom (geneesmiddel) niet kunt gebruiken. XXXXXX?

We beginnen met het berekenen van het aantal ontbrekende waarden (NaN) per geneesmiddel (kolom). Zo krijgen we inzicht in welke geneesmiddelen volledig ontbreken voor de longkankercellijnen en welke gedeeltelijk.

```
Aantal missing values per kolom (top 10):
ABIRATERONE (BRD:BRD-K50071428-001-03-3)          93
BAN-ORL-24 (BRD:BRD-K47049295-300-01-5)           93
SODIUM-TANSHINONE-II-A-SULFONATE (BRD:BRD-K84798689-236-02-9) 93
SULFAMETHAZINE (BRD:BRD-K11640013-236-10-1)        93
NELARABINE (BRD:BRD-K84466663-001-05-4)            93
JNJ-16259685 (BRD:BRD-K25596805-001-01-8)          93
METOPROLOL (BRD:BRD-A03623303-045-09-5)            93
KY02111 (BRD:BRD-K13302470-001-02-7)              93
NIRIDAZOLE (BRD:BRD-K53123955-001-10-5)            93
RG108 (BRD:BRD-K89391146-001-08-0)                 93
dtype: int64
```

```
Aantal missing values per kolom (minst 10):
KW-2478 (BRD:BRD-K41213548-001-02-0)              1
```

GDC-0349 (BRD:BRD-K43187018-001-03-3)	1
RUBITECAN (BRD:BRD-K79821389-001-03-5)	0
SB-2343 (BRD:BRD-K98795921-001-01-7)	0
OTS167 (BRD:BRD-K53417444-003-03-1)	0
TUSEDOSTAT (BRD:BRD-K92241597-001-06-0)	0
VERUBULIN (BRD:BRD-K42673188-001-01-1)	0
BERZOSERTIB (BRD:BRD-K04701033-001-03-9)	0
PF-05212384 (BRD:BRD-K07955840-001-02-3)	0
depmap_id	0
dtype: int64	

Observaties en keuze van geneesmiddel

Observaties: - Slechts enkele geneesmiddelen hebben geen missende waarden voor alle 93 longkankercellijnen. - De meeste andere geneesmiddelen missen waarden in een deel of alle cellijnen. - Voor de meeste geneesmiddelen zou ik dus een deel van de cellijnen moeten verwijderen, waardoor het aantal samples kleiner wordt.

Omdat het aantal longkankercellijnen al heel beperkt is ($n = 93$), is er gekozen voor een geneesmiddel zonder missende responswaarden. Hierdoor blijven alle beschikbare samples behouden voor het trainen en evalueren van het Random Forest-model.

Naast datakwaliteit en samplegrootte is ook gekeken naar het biologische werkingsmechanisme van de overgebleven geneesmiddelen. In een latere fase van het project wordt pathway-aggregatie toegepast om de grote hoeveelheid mutatie- en methyleringsfactoren te reduceren en biologisch interpreteerbaar te maken. Daarom is het wenselijk om een geneesmiddel te kiezen dat aangrijpt op een duidelijk gedefinieerde en goed beschreven biologische pathway.

Twee geneesmiddelen met volledige data voldoen aan deze criteria: - PF-05212384, een duale PI3K/mTOR-remmer, die aangrijpt op een van de meest centrale oncogenese signaalroutes. - Vezosertib, een ATR-kinaseremmer, die betrokken is bij DNA-schadeherstel en celcycluscontrole.

Deze pathways zijn goed beschreven en bevatten meerdere genen, waardoor zij geschikt zijn voor pathway-aggregatie. Dit maakt het mogelijk om te onderzoeken of veranderingen in mutatie- en methyleringspatronen binnen relevante pathways samenhangen met geneesmiddelgevoeligheid. Op deze manier fungeert de keuze van het geneesmiddel ook als een soort controle van het model.

In dit project is gekozen om te starten met PF-05212384, omdat de PI3K/mTOR-pathway uitgebreid is bestudeerd in kanker en vaak verstoort is in longkanker. Dit zal het makkelijker maken om de resultaten van het model eenvoudiger te interpreteren en te relateren aan de bestaande biologische kennis. Vezosertib wordt beschouwd als een mogelijke vervolganalyse om te vergelijken of het Random Forest-model voor een geneesmiddel met een ander werkingsmechanisme andere biologische pathways als belangrijk identificeert.

Deze afwegingen laten zien dat de geneesmiddelkeuze gebaseerd is op een combinatie van datacompleetheid, behoud van samplegrootte en biologische interpretatie.

Stap 4. Harmoniseren van identifiers

Doel: De responsdataset voorbereiden op integratie met de mutatie- en methylatiedata door het gebruik van de gedeelde identifier (**ModelID**). Dit zorgt ervoor dat alle datasets zonder problemen kunnen worden samengevoegd op cellijnniveau.

In de oorspronkelijke responsdataset worden cellijnen geïdentificeerd via de kolom **depmap_id**. In de mutatie- en methylatiedata wordt de naam **ModelID** (DepMap/ACH-ID) gebruikt als standaardidentificer.

Aanpak: - hernoemen van **depmap_id** naar **ModelID**. - controleren van de structuur van de dataset na harmoniseren.

Eerste kolommen na harmonisatie:

```
Index(['ModelID', '8-BROMO-CGMP (BRD:BRD-A00077618-236-07-6)',  
      'NORETYNODREL (BRD:BRD-A00758722-001-04-9)',  
      'PREDNISOLONE-ACETATE (BRD:BRD-A01643550-001-04-9)',  
      'BETAMETHASONE (BRD:BRD-A02180903-001-04-5)'],  
      dtype='object')
```

Aantal cellijnen in responsmatrix: 93

Aantal responskolommen (geneesmiddelen): 1450

	ModelID	8-BROMO-CGMP	NORETYNODREL	PREDNISOLONE-ACETATE	BETAMETHASONE
15	ACH-000840	NaN	0.986123	NaN	NaN
30	ACH-000921	NaN	0.913647	NaN	NaN
89	ACH-000454	NaN	0.934788	NaN	0.978968
92	ACH-000868	NaN	0.790187	NaN	0.690992
93	ACH-000901	NaN	0.921198	NaN	NaN

De identifiers zijn nu consistent (**ModelID**).

Na harmonisatie gebruikt de responsdataset dezelfde identifier (**ModelID**) als de mutatie- en methylatiedatasets. Hierdoor is de dataset technisch gereed voor integratie. De responsmatrix bevat 93 longkankercellijnen (rijen) en 1450 geneesmiddelen (kolommen met AUC-waarden).

Er is bewust nog geen selectie gemaakt voor een specifiek geneesmiddel. Dit zorgt voor een flexibele en reproduceerbare workflow, waarbij dezelfde responsdataset kan worden hergebruikt voor verschillende modellen of analysemogelijkheden.