

Deelvraag 1

Datavoorbewerking en Featureconstructie

Jalisa Shaline van der Zeeuw

2026-01-01

Dit notebook beschrijft de verdere datavoorbewerking en de aggregatie van pathway-features op basis van drie vooraf samengestelde databestanden. Eerst wordt een overzicht gegeven van de reeds opgeschoonde datasets (methylatie, mutatie en responswaarden) welke vervolgens worden samengevoegd. Vervolgens wordt een pathway-aggregatie uitgevoerd om de grote hoeveelheid features te reduceren en geschikt te maken voor supervised machine learning.

Deelvraag 1:

Hoe kan cellijn-data (mutaties, methylatie, drug-respons) worden verzameld, opgeschoond en geschikt gemaakt voor machine learning?

Subdeelvraag:

Hoe kunnen mutatie- en methylatiefeatures door middel van aggregatie worden samengevat naar gen- of pathway-niveau, zodat het aantal features wordt teruggebracht tot een schaal die geschikt is voor supervised machine learning?

Achtergrond van de datasets

Voor dit project worden vier afzonderlijke datasets gebruikt die afkomstig zijn van het [DepMap/CCLE-project](#). Deze datasets beschrijven verschillende moleculaire kenmerken en annotaties van kankercellijnen.

DNA-methylatie

Bestand (ruwe data): *CCLE_RRBS_TSS1kb_20181022.txt*

Deze dataset bevat DNA-methylatiegegevens gemeten met Reduced Representation Bisulfite Sequencing (RBBS). De metingen zijn uitgevoerd in een gebied van ± 1 kilobase (1kb) rondom de transcription start site (TSS) van genen. Dit gebied omvat zowel de promotorregio upstream van de TSS als het 5'-uiteinde van het gen downstream van de TSS, waaronder vaak het eerste exon en/of de 5'untranslated region (5'UTR).

DNA-methylatie in deze regio's is biologisch relevant omdat zij een directe rol speelt in de regulatie van genexpressie. Methylatie van CpG-sites in de promotorregio wordt sterk geassocieerd met transcriptierepressie, doordat methylatie de binding van transcriptiefactoren kan verhinderen en kan bijdragen aan een compactere chromatinestructuur. Methylatie downstream van de TSS in het 5'-gedeelte van het gen kan het starten van transcriptie beïnvloeden en zo de genexpressie moduleren.

Elke rij in deze dataset representeert één CpG-lous en bevat onder andere de volgende relevante metadata:

- **CpG_sites_hg19**: de genomische coördinten van de CpG-sites in het hg19-referentiegenoom.
- **avg_coverage**: de gemiddelde sequencing coverage voor het locus, wat een maat is voor de betrouwbaarheid van de methylatiemeting.

CpG-loci met een lage coverage worden beschouwd als minder betrouwbaar en worden daarom meegenomen in de kwaliteitscontrole en filtering van de data.

Mutaties

Bestand (ruwe data): *OmicSomaticMutations.csv*

Deze dataset bevat de somatische mutatieprofielen van kankercellijnen. Deze mutaties zijn verkregen met behulp van Whole Exome Sequencing (WES). Deze sequencingtechniek richt zich specifiek op de coderende delen van het genoom (exons), die samen ongeveer 1-2% van het totale DNA uitmaken. Ondanks dat dit maar een klein deel van het genoom is, bevatten zij het merendeel van de mutaties die een direct effect hebben op de eiwitstructuur en eiwit functie. Mutaties in deze regio's kunnen leiden tot aminozuurveranderingen, frameshifts of voortijdige stopcodons, wat directe gevolgen kan hebben voor cellulaire processen als proliferatie, apoptose en DNA-schadeherstel.

Niet-coderende regio's, zoals introns en regulatoire elementen, kunnen ook een functionele rol spelen in genregulatie en splicing, maar de effecten van mutaties in deze regio's zijn vaak indirect en moeilijker te voorspellen. Daarnaast leidt het meenemen van het volledige genoom tot een sterke toename in datavolume en complexiteit. In de context van dit onderzoek, waarin het aantal beschikbare cellijnen beperkt is, zou dit de kans op ruis en overfitting in machine learning-modellen sterk vergroten.

Drug-respons

Bestand (ruwe data): *Drug_sensitivity_AUC_(PRISM_Repurposing_Secondary_Screen)_subsetting.csv*

Deze dataset bevat responswaarden van cellijnen op verschillende geneesmiddelen, waarbij de respons is samengevat als area under the curve (AUC) van de dosis-responscurve.

AUC wordt gebruikt omdat het de volledige dosis-responsrelatie samenvat over alle gemeten concentraties. Hierdoor is het minder gevoelig voor meetruis en beter gedefinieerd dan een enkelvoudige maat zoals IC50, dat slechts één punt op de dosis-responscurve representeert. Daarnaast levert AUC een stabiele continue responsvariabele op, wat gunstiger is voor regressiemodellen zoals Random Forest.

Elke kolom (naast de cellijn-identifiers) representeert de respons op één geneesmiddel.

Cellijn-annotaties

Bestand: **Cell_lines_annotations_20181226.txt**

Dit metadatabestand bevat annotaties voor elke cellijn, waaronder:

- **depMapID**,
- weefseltype (**Site_Primary**)
- histologie en andere aanvullende biologische kenmerken

Deze dataset wordt gebruikt om cellijnen te filteren op longkanker en om identifiers tussen de verschillende datasets te harmoniseren.

Samenvatting preprocessing

[hier komt nog het samenvattende flowschema waarin de stappen te zien zijn en aantal features en cellijn voor en na]

De uitgebreide data-preprocessing is uitgevoerd en beschreven in de volgende notebooks:

- dataprep_methylation.ipynb
- dataprep_mutation.ipynb
- dataprep_response.ipynb

Data-integratie

Doel: Het samenvoegen van de afzonderlijke opgeschoonde datasets (mutaties, methylatie en geneesmiddelrespons) tot één geïntegreerde dataset op basis van een gedeelde identifier (ModelID).

Deze stap maakt het mogelijk om:

- de overlap tussen datasets te controleren,
- inzicht te krijgen in het uiteindelijke aantal cellijnen en features,
- en een dataset te creëren die direct geschikt is voor supervised machine learning.

Eerst worden de geprepareerde datasets ingeladen. In eerdere notebooks zijn de datasets afzonderlijk voorbereid, opgeschoond en opgeslagen als pickle-bestanden. Pickle bestanden worden gebruikt om DataFrames exact met datatype en index te bewaren, zodat de data later eenvoudig kan worden ingeladen.

Vervolgens wordt gecontroleerd of de index van elke dataset correct is ingesteld op ModelID. Dit voorkomt fouten bij het samenvoegen en zorgt dat de dataset op dezelfde unieke identifier worden gematcht.

Daarna wordt een inner join uitgevoerd op de ModelID-index van alle drie datasets. Dit houdt in dat alleen cellijnen die in alle drie datasets volledig overeenkomende rijen bevat zodat downstream analyses geen ontbrekende cellijnen bevatten.

Tot slot wordt ter controle de vorm van de gecombineerde dataset weergegeven, zodat snel kan worden gecontroleerd hoeveel cellijnen en features beschikbaar zijn.

Output:

Mutatie index correct ingesteld.

Methylatie index correct ingesteld.

Respons index correct ingesteld.

Aantal cellijnen in alle datasets: 82

Vorm van de gecombineerde dataset: (82, 18025)

Mutatiefeatures: 7358 Methylatiefeatures: 10667 AUC-responswaarden: 1450

Conclusie: Het aantal features in de gecombineerde dataset (mutaties + methylatie) is met 18025 veel hoger dan het aantal samples (82 cellijnen). Om te voorkomen dat dit leidt tot overfitting in het Random Forest-model, wordt in de volgende stap een pathway-aggregatie toegepast om de features biologisch te groeperen en het aantal features te reduceren.

De gecombineerde dataset van mutatie- en methylatiefeatures bevat 18025 features, terwijl slechts 82 cellijnen (samples) beschikbaar zijn. Deze verhouding vraagt om een reductie van de dimensionaliteit van de data voordat modeltraining kan plaatsvinden. Dit heeft geleid tot de formulering van een subdeelvraag en keuze voor aggregatie op pathway-niveau, die in de volgende stap verder wordt uitgewerkt.

Pathway Aggregatie

Doel: Het aantal features in de gecombineerde dataset (`combined_df`) reduceren door deze te aggregeren naar pathway-niveau. In plaats van duizenden individuele genen of CpG-loci te gebruiken, vertegenwoordigt elke pathway één samengevatte feature. Hierdoor wordt de dataset overzichtelijker en beter beheersbaar voor machine learning.

Voor aggregatie wordt gebruik gemaakt van de [MSigDB \(Molecular Signatures Database\)](#), een veelgebruikte en goed gedocumenteerde recourse in de bioinformatica en kankeronderzoek. MSigDB bevat verschillende verzamelingen van pathways. In dit project zijn de Hallmarks gene sets van MSigDB gebruikt. Deze collectie bestaat uit 50 samengestelde pathways die belangrijke biologische processen representeren, waaronder proliferatie, DNA-schadeherstel, apoptose en oncogene signaalroutes.

Koppelen van Genen aan Pathways.

Voordat aggregatie kan plaatsvinden, moeten individuele features worden gekoppeld aan hun bijbehorende pathways.

Voor de methylatiedata betekent dit een extra stap: de oorspronkelijke features zijn CpG-loci met een naamgeving waarin het gen in de genomische locatie zijn opgenomen (bijvoorbeeld `AZIN2_1_33545713_33546713`). Voor aggregatie worden deze kolomnamen eerst teruggebracht tot het bijbehorende gen (zoals in het voorbeeld `AZIN2`), zodat methylatie- en mutatiegegevens op hetzelfde gen-niveau kunnen worden gekoppeld aan pathways.

Aanpak: De Hallmark gene sets worden ingelezen, genen worden gekoppeld aan pathways, en controles worden uitgevoerd om te verifiëren dat alle pathways correct zijn ingelezen.

Output:

Aantal pathways ingelezen: 50

Eerste 5 pathways: ['HALLMARK_ADIPOGENESIS', 'HALLMARK_ALLOGRAFT_REJECTION', 'HALLMARK_ANDROGEN'

Aantal genen in HALLMARK_ADIPOGENESIS: 200

Eerste 5 genen: ['ABCA1', 'ABCB8', 'ACAA2', 'ACADL', 'ACADM']

Waarnemingen: Na het inlezen van de Hallmark gene sets blijken alle 50 pathways aanwezig te zijn. Ter controle is de eerste pathway (`HALLMARK_ADIPOGENESIS`) geïnspecteerd. Deze bevat 200 genen, waaronder bekende genen zoals *ABCA1*, *ABCB8*, *ACAA2*, *ACADL* en *ACADM*. Dit bevestigt dat de koppeling tussen MSigDB en de gen-namen in de dataset correct is verlopen.

Samenvattende Statistiek + Overlap van Genen

Voordat de daadwerkelijke aggregatie kan worden uitgevoerd, is het belangrijk om inzicht te krijgen in de samenstelling van de pathways. Daarom wordt er eerst gekeken naar de grootte van elke pathway (het aantal genen) en de mate waarin genen in meerdere pathways voorkomen.

Deze analyse geeft inzicht in redundantie en overlap tussen pathways. Dit is relevant omdat overlappende genen ertoe kunnen leiden dat pathway-features deels op dezelfde onderliggende genetische informatie zijn gebaseerd en daardoor onderling gecorreleerd kunnen zijn.

Output:

Het aantal genen per pathway varieert van 32 tot 200 genen, met gemiddeld 146 genen per pathway (± 62). Van de 4384 unieke genen die in de 50 Hallmark pathways voorkomen, komen er 1713 genen (39%) in meerdere pathways voor, terwijl 2671 genen (61%) slechts in één pathway aanwezig zijn.

Conclusie: Bij de aggregatie van genen naar pathway-level features blijkt dat een groot deel van de genen in meerdere pathways voorkomt, terwijl andere genen slechts in één pathway aanwezig zijn. Deze overlap is biologisch verklaarbaar, aangezien genen vaak meerdere processen reguleren. Hierdoor zijn sommige pathway-scores deels gecorreleerd: verandering in één gen kunnen meerdere pathway-features tegelijk beïnvloeden.

In tegenstelling tot andere ML-modellen kan Random Forest goed omgaan met deze gecorreleerde features. Random Forest combineert meerdere decision trees die elk splitsingen maken op individuele features. Wel kan deze correlatie invloed hebben op de interpretatie van feature importance, doordat het belang van twee sterk verwante pathways kan worden verdeeld over meerdere features.

Aggregatie naar pathway level features

In deze stap worden individuele genen (en bij methylatie: CpG-loci die aan genen zijn gekoppeld) samengevat tot pathway-level features. Voor elke Hallmark-pathway wordt één nieuwe feature aangemaakt die de status van dat biologische proces per cellijn representeert.

De oorspronkelijke mutatiedata bestaat uit binaire waarden per gen (0 = geen mutatie, 1 = mutatie aanwezig). Bij aggregatie op pathway-niveau worden deze binaire waarden samengevat door het gemiddelde te nemen over alle genen die tot een pathway behoren. Hierdoor ontstaat per cellijn een continue pathwayscore tussen 0 en 1, die de mate waarin genen binnen een pathway gemuteerd zijn samenvat.

Voor metylatie geldt dat de oorspronkelijke waarden al continue zijn. Het gemiddelde per pathway vat hier de algemene methylatiestatus van de betrokken genen samen en geeft een globale indicatie van mogelijke pathway activatie of repressie.

In deze analyse is gekozen voor het gemiddelde als samenvattende maat omdat deze:

- informatie over alle genen in het pathway behoudt,
- gevoeliger is voor sterke afwijkingen die biologisch relevant kunnen zijn,
- en het resulteert in continue features op een vergelijkbare schaal voor mutatie en methylatie.

Alternatieve samenvattende maten, zoals mediaan of variantie per pathway, worden niet in de eerste analyse toegepast, maar zijn wel een mogelijkheid in een latere fase van het project.

Ter controle wordt de vorm van de resulterende pathway-matrix weergegeven en een voorbeeld van de eerste twee mutatie-pathway features en de eerste twee methyлатie-pathwayfeatures. Op basis van de Hallmark gene sets wordt verwacht dat de matrix 50 mutaties- en 50 methyлатie-pathway features bevat (in totaal dus 100 features).

Vorm van pathway-level feature matrix: (82, 100)

	MUT_ADIPOGENESIS	MUT_ALLOGRAFT_REJECTION	METH_ADIPOGENESIS	METH_ALLOGRAFT_REJECTION
ModelID				
ACH-000012	0.015873	0.012048	0.272330	0.400000
ACH-000035	0.000000	0.000000	0.172558	0.300000
ACH-000062	0.015873	0.012048	0.166824	0.300000
ACH-000066	0.000000	0.012048	0.173513	0.300000
ACH-000161	0.015873	0.000000	0.285914	0.300000

De output laat zien dat de aggregatie naar pathway-niveau succesvol is uitgevoerd. De resulterende dataset bevat uitsluitend cellijnen die in alle drie de oorspronkelijke datasets aanwezig zijn. Door aggregatie is het aantal features sterk gereduceerd ten opzichte van de oorspronkelijke gen- en CpG-level data, terwijl de biologische interpretatie behouden blijft.

De voorbeeldweergave van de matrix bevestigt dat:

- elke rij één longkankercellijn representeert (`ModelID`), - de mutatie- en methyлатie-features duidelijk van elkaar te onderscheiden zijn, - en elke feature overeenkomt met één biologische pathway.

Hiermee is een compacte en overzichtelijke featurematrix verkregen die geschikt is als input voor machine learning.

De pathway-level featurematrix wordt opgeslagen als pickle-bestand (`pathway_features.pkl`) in de map `data/processed`, zodat deze direct herbruikbaar is voor het trainen en evalueren van machine learning-modellen.

De resulterende pathway-level featurematrix wordt opgeslagen als pickle-bestand (`pathway_features.pkl`) in de map `data/processed`.

Output:

Pathway-level featurematrix opgeslagen als:
`data/processed/pathway_features.pkl`

Scheiding tussen inputfeatures (X) en responswaarden (y)

De responsdata (`lung_response_df.pkl`) bevat bewust nog meerdere geneesmiddelen per cellijn. Deze keuze is gemaakt om de pipeline reproduceerbaar en flexibel te houden: bij het trainen van een machine learning-model kan binnen scikit-learn eenvoudig één specifiek geneesmiddel worden geselecteerd als doelvariabele (y), zonder dat de onderliggende data opnieuw hoeft te worden geprepareerd.

De afweging en selectie van het geneesmiddel is onderbouwd in het notebook `dataprep_response_df.ipynb`. Daar is vastgesteld dat slechts een beperkt aantal geneesmiddelen volledige responswaarden bevat

voor alle longkankercellijnen. Op basis van datacompleteheid en biologisch werkingsmechanisme zijn twee kandidaten geselecteerd, waarbij eerst wordt gestart met PF-05212384. Een tweede geneesmiddel (Berzosertib) is benoemd als mogelijke vervolganalyse.

Door de responsdata gescheiden te houden van de featurematrix (X) en pas bij modeltrianing een specifieke keuze te maken voor y, blijft de pipeline overzichtelijk en herbruikbaar met de werkwijze van supervised machine learning in scikit-learn.

Beantwoording van de deelvraag

De deelvraag *“Hoe kan cellijn-data (mutaties, methylatie, drug-respons) worden verzameld, opgeschoond en geschikt gemaakt voor machine learning?”* is in dit notebook (met bijbehorende subnotebooks) beantwoord door het opzetten van een volledige en reproduceerbare datapreprocessing- en integratiepipeline.

In afzonderlijke notebooks zijn:

- mutatie-, methylatie- en responsdata ingelezen en verkend,
- longkankercellijnen geselecteerd,
- kwaliteitscontrole uitgevoerd,
- cellijnen geharmoniseerd met behulp van standaard DepMap-identifiers,
- en moleculaire data geaggregeerd naar pathway-level features.

In dit notebook zijn deze datasets vervolgens geïntegreerd tot één consistente featurematrix die geschikt is als input voor supervised machine learning. De resulterende dataset vormt de basis voor de vervolganalyse, waarin een Random Forest model wordt getraind en geëvalueerd om verbanden tussen moleculaire kenmerken en therapierespons te onderzoeken.