

Deelvraag 2

Analyse van Feature Importance in een Random Forest-model

Jalisa Shaline van der Zeeuw

2026-01-01

Analyse van Feature Importance in een Random Forest-mode

In dit notebook wordt één geneesmiddel geselecteerd om de interpretatie van het Random Forest-model op pathway-niveau te demonstreren.

Zoals eerder beschreven is de keuze voor PF-05212384 gebaseerd op een combinatie van datacomplexiteit, behoud van samplegrootte en de beschikbaarheid van bestaande biologische kennis, wat het mogelijk maakt om modeluitkomsten beter te interpreteren.

Doel: Het doel van deze analyse is niet om conclusies te trekken over dit specifieke geneesmiddel, maar om te laten zien hoe een machine learning-model biologische pathway-informatie gebruikt bij het voorspellen van therapierespons.

In een vervolganalyse kan deze pipeline worden toegepast op een geneesmiddel met een ander werkingsmechanisme, zoals *Bezosertib*, om te onderzoeken of het Random Forest-model andere biologische pathways als belangrijk identificeert.

[de nieuwe 2 deelvraag nog verwerken in de inleiding]

Data-invoer en selectie

Voor deze analyse worden twee datasets gebruikt:

- X: een pathway-level featurematrix, voorbereid in notebook *deelvraag_dataprep.ipynb* (*pathway_features.pkl*).
- y: drug-responsdata, voorbereid in notebook *dataprep_response.ipynb* (*response_matrix.pkl*)

Om datalek te voorkomen worden features (X) en respons (y) gescheiden ingeladen. Ter controle wordt eerst de shape van beide datasets weergegeven. Vervolgens kan er een geneesmiddel worden geselecteerd uit de responsmatrix dat in de verdere analyse wordt gebruikt.

Tot slot worden de featurematrix en de geselecteerde responsvector op elkaar afgestemd, waarbij uitsluitend cellijnen worden meegenomen waarvoor zowel pathway-features als responsdata beschikbaar zijn. Na afstemming vormen *X_aligned* en *y_aligned* de definitieve dataset die wordt gebruikt voor modeltraining en verdere analyse.

Output:

Featurematrix (X): (82, 100)

Responsmatrix (y): (93, 1450)

Aantal cellijnen met responsdata (vóór afstemming met features): 93

Aantal cellijnen na afstemming: 82

Trainen van het model

[korte introductie van het model, met verwijzing naar een apart bewijsstuk/bijlage voor verdieping, wat voor model, waarom dit model geschikt is voor deze data, wat er mee wordt gedaan (interpretatie)]
In deze stap wordt een Random Forest-regressiemodel getraind op de afgestemde dataset (`X_aligned` en `y_aligned`). Deze analyse is gericht op het verkrijgen van inzicht in welke pathway-gebaseerde features door het model worden gebruikt bij het voorspellen van therapierespons, en niet op het evalueren van de voorspellende prestaties.

Het model wordt getraind op de volledige beschikbare dataset, zodat alle informatie kan worden benut voor de analyse van feature importance. Om deze reden wordt in deze fase bewust geen train-test-splitsing toegepast.

De Random Forest die in dit notebook wordt getraind, fungeert puur als interpretatiemodel. In het vervolg bij deelvraag 3 wordt een afzonderlijke Random Forest-model opgebouwd, waarin met behulp van een train-test-splitsing de generaliseerbaarheid en prestaties van het model worden geëvalueerd.

Er is gekozen voor een relatief hoog aantal bomen om stabiliteit van de feature importance te vergroten.

Inputdata gecontroleerd: klaar voor modeltraining.

Random Forest-model succesvol getraind.


Feature Importance

Feature importance binnen een Random Forest geeft aan in welke mate individuele features bijdragen aan het maken van voorsellingen door het model. De feature importance weerspiegelt hoe vaak en hoe effectief pathway-gebaseerde kenmerken worden gebruikt om de therapierespons van longkankercellijnen te voorspellen.

Een hogere feature importance betekent dat een pathway relatief meer bijdraagt aan het verkleinen van de voorspelfout van het model. Deze maat geeft daarmee inzicht in welke biologische pathways het model als het meest informatief beschouwd.

Om deze informatie overzichtelijk te presenteren, worden de feature importances gevisualiseerd in figuren. Zowel de meest invloedrijke individuele pathways als de relatieve bijdrage van mutatie- en methylieringspathways worden afzonderlijk weergegeven.

Individuele Pathway Importance



Figuur 1. Top 15 pathways met de hoogste feature importance volgens het Random Forest-model.

Figuur 1 laat zien dat meerdere van de hoogst gerangschikte pathways gebaseerd zijn op DNA-methylatiegegevens. Dit wijst erop dat epigenetische kenmerken een belangrijke rol spelen in de voorspelling van therapierespons.

De hoogste feature importances worden toegekend aan de volgende methylatie gebaseerde pathways:

- Androgen_response (hormonale signaaltransductie)
- Hedgehog_signaling (ontwikkelingsgerelateerde signaling)
- UV_response_dn (cellulaire stressresponsen)

Deze pathways vormen daarmee de meest informatieve kenmerken binnen dit model.

Ook zijn er enkele mutatie-gebaseerde pathways aanwezig in de top van de ranglijst, wat aangeeft dat zowel genetische als epigenetische informatie bijdraagt aan de voorspelling van therapierespons. De relatieve verdeling tussen deze twee wordt in de volgende stap geanalyseerd.

Mutatie versus Methylatie

[zelfe maar groepen op type. verdeling en relatieve bijdrage]

Om de feature importance verder samen te vatten, worden de pathway-features gegroepeerd op basis van hun herkomst: mutatie of DNA-methylatie. Door de verdeling van de feature importances binnen beide groepen te vergelijken, wordt inzicht verkregen in de relatieve bijdrage van genetische en epigenetische informatie aan het model.


Output controle van de groepering:

```
Type
Methylatie    50
Mutatie       50
Name: count, dtype: int64
```

Biologische interpretatie van de belangrijkste pathways

Pathways met de hoogste feature importance kunnen nader worden bekeken vanuit biologisch perspectief. Het doel is hierbij niet om te concluderen dat specifieke pathways de therapierespons veroorzaken, maar om te onderzoeken of welke kanker-gerelateerde biologische processen door het model als belangrijk worden beschouwd.

Deze analyse dient ter ondersteuning van de interpretatie van het model en plaatst de uitkomsten van de pathway-analyse in een biologische context.



Figuur 2. *Verdeling van feature importance per type feature. Methylatie-features vertonen een gemiddelde importance van 0.013 ($SD = 0.009$; $min = 0.002$; $max = 0.053$), terwijl mutatie-features een gemiddelde importance hebben van 0.007 ($SD = 0.007$; $min = 0.001$; $max = 0.038$).*

De boxplot in figuur 2 laten zien dat methylatie-pathways over het algemeen hogere feature importance-waarden hebben dan mutatie-pathways. Zowel de mediaan als het grootste deel van de verdeling ligt bij methylatie hoger, terwijl mutatie-pathways voornamelijk lagere importance-waarden vertonen.

Voor beide groepen is de verdeling scheef, met een beperkt aantal pathways die duidelijk hogere importance-waarden hebben dan de rest. Deze hoogst gerangschikte pathways worden in de boxplot als uitbijters weergegeven en laten zien dat de bijdrage van individuele pathways sterk varieert binnen het

Beantwoording van de deelvraag

In dit notebook is onderzocht welke pathway-geaggregeerde mutatie- en methylatiekenmerken door een Random Forest-model worden gebruikt bij het voorspelen van therapierespons in longkankercellen.

Door features importance te analyseren op zowel individuele pathway-niveau als op het niveau van mutatie- versus methylatie-informatie, is inzicht verkregen in het type biologische processen dat door het model wordt benadrukt.

.....