

pop

December 1, 2025

Proof of Principle (PoP)

Inleiding & Doel

Proof-of-Principle: kan een ML-model mutatieprofielen van longkankercellijnen gebruiken om respons op een drug te voorspellen?

[hier komt uitleg over bewijsstuk]

Data Inladen

In deze stap laden we de originele pickles (mut_matrix.pkl en lung_response_df.pkl) in en worden kopieën gemaakt voor de PoP-analyse. Er wordt een print uitgevoerd van de shape en een klein deel van de data om te zien hoe de ModelID-indexen eruitzien.

Proof of Principle (PoP)

Inleiding & Doel

Proof-of-Principle: kan een ML-model mutatieprofielen van longkankercellijnen gebruiken om respons op een drug te voorspellen?

[hier komt uitleg over bewijsstuk]

Data Inladen

In deze stap laden we de originele pickles (mut_matrix.pkl en lung_response_df.pkl) in en worden kopieën gemaakt voor de PoP-analyse. Er wordt een print uitgevoerd van de shape en een klein deel van de data om te zien hoe de ModelID-indexen eruitzien.

```
mut_pop shape: (174, 7358)
```

```
response_pop shape: (93, 1451)
```

```
mut_pop sample (3 rows, 3 cols):
```

```
HugoSymbol  A1CF  A2M  A2ML1
```

```
ModelID
```

```
ACH-000012      0    0      0
```

```
ACH-000015      0    0      0
```

```
ACH-000021      0    0      0
```

```
response_pop sample (3 rows, 5 cols):
```

```
ModelID  8-BROMO-CGMP (BRD:BRD-A00077618-236-07-6) \
```

15	ACH-000840	NaN
30	ACH-000921	NaN
89	ACH-000454	NaN

```

    NORETYNODREL (BRD:BRD-A00758722-001-04-9)
15                0.986123
30                0.913647
89                0.934788

```

```

mut_pop shape: (174, 7358)
response_pop shape: (93, 1451)

```

```
mut_pop sample (3 rows, 3 cols):
```

HugoSymbol	A1CF	A2M	A2ML1
ModelID			
ACH-000012	0	0	0
ACH-000015	0	0	0
ACH-000021	0	0	0

```
response_pop sample (3 rows, 5 cols):
```

	ModelID	8-BROMO-CGMP (BRD:BRD-A00077618-236-07-6)	\
15	ACH-000840	NaN	
30	ACH-000921	NaN	
89	ACH-000454	NaN	

```

    NORETYNODREL (BRD:BRD-A00758722-001-04-9)
15                0.986123
30                0.913647
89                0.934788

```

Inspectie en fix ModelID

In `response_pop` staat `ModelID` nog als kolom en de index is integer (0, 1, 2, ...). Dit veroorzaakt later een `keyError` bij het mergen van de datasets.

Oplossing:

- Zet `ModelID` in `response_pop` om naar de index.
- Zorg dat de index het juiste format heeft: ACH-XXXXX.

```

response_pop index after fix (first 3): Index(['ACH-000840', 'ACH-000921',
'ACH-000454'], dtype='object', name='ModelID')
response_pop shape: (93, 1450)

```

```
response_pop sample (3 rows, 3 cols):
```

	8-BROMO-CGMP (BRD:BRD-A00077618-236-07-6)	\
ModelID		
ACH-000840	NaN	
ACH-000921	NaN	

ACH-000454 NaN

NORETYNODREL (BRD:BRD-A00758722-001-04-9) \

ModelID

ACH-000840 0.986123

ACH-000921 0.913647

ACH-000454 0.934788

PREDNISOLONE-ACETATE (BRD:BRD-A01643550-001-04-9)

ModelID

ACH-000840 NaN

ACH-000921 NaN

ACH-000454 NaN

Driver-genen en beschikbare drugs

[uitleg over subset driver genen en cellijnen en drug kiezen en over ingebouwde controle die ik heb toegevoegd]

Driver genen aanwezig in dataset: ['EGFR', 'KRAS', 'BRAF', 'ALK', 'ROS1', 'ERBB2', 'MET', 'TP53', 'PIK3CA', 'STK11']

Aantal cellijnen in subset die ook responsdata hebben: 89

Aantal drugs zonder missing values in subset van 89 cellijnen: 7

Beschikbare drugs:

- BERZOSERTIB (BRD:BRD-K04701033-001-03-9)
- PF-05212384 (BRD:BRD-K07955840-001-02-3)
- VERUBULIN (BRD:BRD-K42673188-001-01-1)
- OTS167 (BRD:BRD-K53417444-003-03-1)
- RUBITECAN (BRD:BRD-K79821389-001-03-5)
- TOSEDOSTAT (BRD:BRD-K92241597-001-06-0)
- SB-2343 (BRD:BRD-K98795921-001-01-7)

Subset van cellijnen en features maken

Voor deze PoP heb ik de volgende keuzes gemaakt:

- Drug: PF-05212384 (BRD:BRD-K07955840-001-02-3).
Dit is een PI3K/mTOR inhibitor, relevant voor mutaties in PIK3CA, één van de driver-genen in onze subset. De responsdata voor deze drug is volledig aanwezig in de geselecteerde cellijnen.
- Samples (cellijnen): 30 uit de 89 beschikbare cellijnen.
Dit is een kleine subset om snel een proof-of-principle model te trainen en evalueren.
- Features (mutaties):
 - 10 driver-genen: top 10 meest biologisch relevante genen. Onder deze genen is PIK3CA waarvan de mutaties naar verwachting invloed hebben op de repons op de gekozen drug PF-05212384 (PI3K/mTOR inhibitor).
 - 20 random gekozen genen.

- Train/test split: 80/20 Voldoende cellijnen om een klein model te trainen (24 cellijnen) en testen (6 cellijnen) voor evaluatie.

X_pop shape: (30, 30)

y_pop shape: (30,)

Voorbeeld X_pop (eerste 3 rijen, eerste 5 kolommen):

HugoSymbol	EGFR	KRAS	BRAF	ALK	ROS1
ModelID					
ACH-000062	0	0	0	0	0
ACH-000627	0	0	0	0	0
ACH-000444	0	1	0	0	0

Voorbeeld y_pop (eerste 3 rijen):

ModelID	
ACH-000062	0.602987
ACH-000627	0.600329
ACH-000444	0.638270

Name: PF-05212384 (BRD:BRD-K07955840-001-02-3), dtype: float64

Train/test split en scikit-learn model

[uitleg over train/test split (en model?)]

X_train shape: (24, 30)

X_test shape: (6, 30)

y_train shape: (24,)

y_test shape: (6,)

RandomForestRegressor trainen + voorspellen + evalueren

Evalueren Voor het evalueren van het Random Forest regressiemodel heb ik verschillende evaluatiemaatstaven gebruikt.

- **R²** (R-squared, determinatiecoëfficiënt) R² is een maat voor hoe goed het model de variatie in de respons (AUC) kan verklaren op basis van mutaties.

Interpretatie:

-R² = 1 -> perfecte voorspelling.

-R² = 0 -> model voorspelt even goed als het gemiddelde, geen voorspellend vermogen.

-R² < 0 -> model presteert slechter dan gemiddeld.

R² zegt niets over hoeveel voorspellingen exact correct zijn, maar geeft aan hoeveel van de verschillen in AUC tussen samples door het model kan worden verklaard.

- **RMSE** (Root Mean Squared Error) RMSE geeft de gemiddelde fout van het model weer in dezelfde eenheid als de respons (AUC)

Gemiddeld wijkt de voorspelling van het model $\pm$ RMSE af van de werkelijke AUC.

- **(optioneel) MAE** (Mean Absolute Error) MAE is het gemiddelde van de absolute fouten tussen voorspelde en werkelijke AUC.

Het voordeel is dat MAE niet sterk wordt beïnvloed door een paar extreem afwijkende waarden in de data. Het laat dus een realistischer beeld zien van de typische fout van het model.

Door R^2 , RMSE en MAE te combineren ontstaat er een compleet beeld van zowel het voorspellend vermogen van het model (R^2) als de grootte van de voorspelfouten in de schaal van de AUC (RMSE en MAE). Voor deze proof of principle is vooral relevant dat kan worden aangetoond dat het model enig signaal uit de mutaties kan oppikken en dat de volledige machine-learning pipeline succesvol kan worden uitgevoerd.

Resultaten:

R^2 score: 0.08349045280315626

MSE: 0.0035071847026042122

RMSE: 0.05922148852067307

MAE: 0.04720569490411688

y_min: 0.529217848063749

y_max: 0.777116758208797

Conclusie

De R^2 score betekent dat ongeveer 8% van de variatie in de gemeten AUC-waarden kan worden verklaard door het model. Het model pikt dus een klein signaal uit de mutaties. Dit is normaal bij slechts 30 samples en 30 binaire features. Voor een proof-of-principle is dit voldoende bewijs dat de pipeline werkt en dat er ten minste een zwak patroon in de data aanwezig is.

De RMSE geeft aan dat de voorspellingen gemiddeld ongeveer 0.06 AUC-punten van de gemeten responswaarden afwijken. De MAE laat zien dat de gemiddelde afwijking 0.047 AUC bedraagt en ligt zoals verwacht iets lager dan de RMSE, omdat RMSE grotere fouten zwaarder meeweegt.

Of deze fouten groot of klein zijn, hangt af van de spreiding van de responswaarden in de dataset. In deze subset liggen de AUC-responswaarden afgerond tussen de 0.53 en 0.78. Relatief gezien betekent dat een fout van ongeveer 0.05 dat de voorspellingen een klein tot matig deel van de totale variatie missen, wat logisch is bij een kleine dataset. Fouten worden het beste beoordeeld in verhouding tot de spreiding in de responswaarden, en niet aan een vaste grens.

De volledige pipeline werkt (inladen > train/test split > trainen > voorspellen > evalueren). De evaluatiematen zijn berekend en geïnterpreteerd. De resultaten laten zien dat er enige voorspellende waarde in de mutaties zit, en de cijfers zijn realistisch gezien de kleine dataset. De proof-of-principle is geslaagd.

Feature importance

[Hier ben ik nog mee bezig, komt later]

Bron in scikit-learn: User Guide → Supervised Learning → Regression Ensemble methods → RandomForestRegressor Metrics → Regression metrics