

Proof of Principle

Technische verkenning van de analysepipeline op een beperkte dataset

Jalisa Shaline van der Zeeuw

2026-01-01

Dit notebook beschrijft een proof of principle waarin op kleine schaal wordt getest of onderdelen van de analysepipeline technisch uitvoerbaar zijn voor het voorspellen van geneesmiddelenrespons op basis van mutatieprofielen van longkankercellijnen.

Het doel van deze PoP is niet om een optimaal of volledig uitgewerkt voorspellend model te ontwikkelen, maar om te kijken of de gekozen aanpak en analysemethoden technisch uitvoerbaar zijn. Een PoP kan worden ingezet als eerste verkennende stap binnen een groter onderzoeksproject. Door te werken met een beperkte subset van data en vereenvoudigde pipeline kan worden vastgesteld of de onderdelen van de workflow goed functioneren en logisch op elkaar aansluiten. Dit voorkomt dat in een later stadium veel tijd wordt geïnvesteerd in een complexe analyse die methodologisch of technisch toch niet haalbaar blijkt. In deze PoP wordt daarom stap voor stap getest of belangrijke onderdelen van de pipeline uitvoerbaar zijn: het inladen en inspecteren van de data, het corrigeren en harmoniseren van identifiers, het selecteren van relevante cellijnen, diver-genen en geneesmiddelen, het samenstellen van een geschikte featurematrix, en het trainen en evalueren van een eerste machine-learning model met behulp van een RandomForestRegressor uit scikit-learn.

Data Inladen

In deze stap laden we de originele pickles (mut_matrix.pkl en lung_response_df.pkl) in en worden kopieën gemaakt voor de PoP-analyse. Er wordt een print uitgevoerd van de shape en een klein deel van de data om te zien hoe de ModelID-indexen eruitzien.

```
mut_pop shape: (174, 7358)
```

```
response_pop shape: (93, 1451)
```

```
mut_pop sample (3 rows, 3 cols):
```

```
HugoSymbol  A1CF  A2M  A2ML1
```

```
ModelID
```

```
ACH-000012      0    0      0
```

```
ACH-000015      0    0      0
```

```
ACH-000021      0    0      0
```

```
response_pop sample (3 rows, 5 cols):
```

```
ModelID  8-BROMO-CGMP (BRD:BRD-A00077618-236-07-6) \
```

15	ACH-000840	NaN
30	ACH-000921	NaN
89	ACH-000454	NaN

NORETYNODREL (BRD:BRD-A00758722-001-04-9)		
15		0.986123
30		0.913647
89		0.934788

Inspectie en fix ModelID

In `response_pop` staat `ModelID` nog als kolom en de index is integer (0, 1, 2, ...). Dit veroorzaakt later een `keyError` bij het mergen van de datasets.

Oplossing:

- Zet `ModelID` in `response_pop` om naar de index.
- Zorg dat de index het juiste format heeft: `ACH-XXXXX`.

```
response_pop index after fix (first 3): Index(['ACH-000840', 'ACH-000921', 'ACH-000454'], dtype='object', name='ModelID')
response_pop shape: (93, 1450)
```

```
response_pop sample (3 rows, 3 cols):
      8-BROMO-CGMP (BRD:BRD-A00077618-236-07-6) \
ModelID
ACH-000840                                NaN
ACH-000921                                NaN
ACH-000454                                NaN
```

```
      NORETYNODREL (BRD:BRD-A00758722-001-04-9) \
ModelID
ACH-000840                                0.986123
ACH-000921                                0.913647
ACH-000454                                0.934788
```

```
      PREDNISOLONE-ACETATE (BRD:BRD-A01643550-001-04-9)
ModelID
ACH-000840                                NaN
ACH-000921                                NaN
ACH-000454                                NaN
```

Driver-genen en beschikbare drugs

Om het overzichtelijk en biologisch relevant te houden, heb ik de analyse beperkt tot een kleine, vooraf samengestelde set van bekende driver-genen bij longkanker. Deze genen zijn geselecteerd omdat

mutaties hierin vaak een rol spelen bij tumorontwikkeling en therapierespons. Eerst is gecontroleerd welke van deze driver-genen daadwerkelijk aanwezig zijn in de mutatiedataset. Vervolgens zijn alleen die cellijnen geselecteerd die minimaal één mutatie in deze genen bevatten en waarvoor ook bijbehorende drug-responsdata beschikbaar is.

Op basis van deze subset is onderzocht voor welke geneesmiddelen volledige responsdata beschikbaar is, zodat de PoP zonder complicaties door missende waarden (NaN) kon worden uitgevoerd. Deze stap heeft als doel om te verifiëren of het selecteren van relevante genen, cellijnen en drugs binnen de pipeline technisch uitvoerbaar is en resulteert in een bruikbare dataset voor het trainen en testen van een eerste machine-learningmodel.

```
Driver genen aanwezig in dataset: ['EGFR', 'KRAS', 'BRAF', 'ALK', 'ROS1', 'ERBB2', 'MET', 'TP53']
Aantal cellijnen in subset die ook responsdata hebben: 89
Aantal drugs zonder missing values in subset van 89 cellijnen: 7
```

Beschikbare drugs:

- BERZOSERTIB (BRD:BRD-K04701033-001-03-9)
- PF-05212384 (BRD:BRD-K07955840-001-02-3)
- VERUBULIN (BRD:BRD-K42673188-001-01-1)
- OTS167 (BRD:BRD-K53417444-003-03-1)
- RUBITECAN (BRD:BRD-K79821389-001-03-5)
- TOSEDOSTAT (BRD:BRD-K92241597-001-06-0)
- SB-2343 (BRD:BRD-K98795921-001-01-7)

Subset van cellijnen en features maken

Op basis van de bovenstaande verkenning heb ik voor deze PoP de volgende keuzes gemaakt:

- Drug: PF-05212384 (BRD:BRD-K07955840-001-02-3).
Dit is een PI3K/mTOR inhibitor, relevant voor mutaties in PIK3CA, één van de driver-genen in onze subset. De responsdata voor deze drug is volledig aanwezig in de geselecteerde cellijnen.
- Samples (cellijnen): 30 uit de 89 beschikbare cellijnen.
Dit is een kleine subset om snel een proof-of-principle model te trainen en evalueren.
- Features (mutaties):
 - 10 driver-genen: top 10 meest biologisch relevante genen. Onder deze genen is PIK3CA waarvan de mutaties naar verwachting invloed hebben op de repons op de gekozen drug PF-05212384 (PI3K/mTOR inhibitor).
 - 20 random gekozen genen.
- Train/test split: 80/20 Voldoende cellijnen om een klein model te trainen (24 cellijnen) en testen (6 cellijnen) voor evaluatie.

Output is als volgt:

```
X_pop shape: (30, 30)
y_pop shape: (30,)
```

Voorbeeld X_pop (eerste 3 rijen, eerste 5 kolommen):

HugoSymbol	EGFR	KRAS	BRAF	ALK	ROS1
ModelID					
ACH-000062	0	0	0	0	0
ACH-000627	0	0	0	0	0
ACH-000444	0	1	0	0	0

Voorbeeld y_pop (eerste 3 rijen):

ModelID	
ACH-000062	0.602987
ACH-000627	0.600329
ACH-000444	0.638270

Name: PF-05212384 (BRD:BRD-K07955840-001-02-3), dtype: float64

Op basis van de gemaakte keuzes is een featurematrix (**X_pop**) en bijbehorende labelvector (**y_pop**) samengesteld. **X_pop** bestaat uit 30 cellijnen en 30 mutatiefeatures (10 driver-genen en 20 willekeurig geselecteerde genen), terwijl **y_pop** de continue drug-responswaarden bevat voor de gekozen drug PF-05212384.

Train/test split en scikit-learn model

Om te voorkomen dat het model wordt geëvalueerd op dezelfde data als waarop het is getraind, moet de data worden opgesplitst in een trainings- en testset. Er is gekozen voor een 80/20 train-test split, wat resulteert in 24 cellijnen voor training en 6 cellijnen voor evaluatie. Door het instellen van een vaste random seed wordt ervoor gezorgd dat de train-test splitsing reproduceerbaar is, zodat dezelfde data-indeling wordt gebruikt bij elke uitvoering van het model.

```
X_train shape: (24, 30)
X_test shape: (6, 30)
y_train shape: (24,)
y_test shape: (6,)
```

RandomForestRegressor trainen + voorspellen + evalueren

Evalueren

[hetvolgende moet ik nog visueel maken]

Voor het evalueren van het Random Forest regressiemodel heb ik verschillende evaluatiemaatstaven gebruikt.

R² (R-squared, determinatiecoëfficiënt) R² is een maat voor hoe goed het model de variatie in de respons (AUC) kan verklaren op basis van mutaties.

Interpretatie:

- R² = 1 -> perfecte voorspelling.
- R² = 0 -> model voorspelt even goed als het gemiddelde, geen voorspellend vermogen.
- R² < 0 -> model presteert slechter dan gemiddeld.

R^2 zegt niets over hoeveel voorspellingen exact correct zijn, maar geeft aan hoeveel van de verschillen in AUC tussen samples door het model kan worden verklaard.

RMSE (Root Mean Squared Error) RMSE geeft de gemiddelde fout van het model weer in dezelfde eenheid als de respons (AUC)

Gemiddeld wijkt de voorspelling van het model $\pm$ RMSE af van de werkelijke AUC.

(optioneel) MAE (Mean Absolute Error) MAE is het gemiddelde van de absolute fouten tussen voorspelde en werkelijke AUC.

Het voordeel is dat MAE niet sterk wordt beïnvloed door een paar extreem afwijkende waarden in de data. Het laat dus een realistischer beeld zien van de typische fout van het model.

Door R^2 , RMSE en MAE te combineren ontstaat er een compleet beeld van zowel het voorspellend vermogen van het model (R^2) als de grootte van de voorspelfouten in de schaal van de AUC (RMSE en MAE). Voor deze proof of principle is vooral relevant dat kan worden aangetoond dat het model enig signaal uit de mutaties kan oppikken en dat de volledige machine-learning pipeline succesvol kan worden uitgevoerd.

Resultaten:

R^2 score: 0.08349045280315659

MSE: 0.003507184702604211

RMSE: 0.059221488520673056

MAE: 0.04720569490411688

y_min: 0.529217848063749

y_max: 0.777116758208797

Conclusie

De R^2 score betekent dat ongeveer 8% van de variatie in de gemeten AUC-waarden kan worden verklaard door het model. Het model pikt dus een klein signaal uit de mutaties. Dit is normaal bij slechts 30 samples en 30 binaire features. Voor een proof-of-principle is dit voldoende bewijs dat de pipeline werkt en dat er ten minste een zwak patroon in de data aanwezig is.

De RMSE geeft aan dat de voorspellingen gemiddeld ongeveer 0.06 AUC-punten van de gemeten responswaarden afwijken. De MAE laat zien dat de gemiddelde afwijking 0.047 AUC bedraagt en ligt zoals verwacht iets lager dan de RMSE, omdat RMSE grotere fouten zwaarder meeweegt.

Of deze fouten groot of klein zijn, hangt af van de spreiding van de responswaarden in de dataset. In deze subset liggen de AUC-responswaarden afgerond tussen de 0.53 en 0.78. Relatief gezien betekent dat een fout van ongeveer 0.05 dat de voorspellingen een klein tot matig deel van de totale variatie missen, wat logisch is bij een kleine dataset. Fouten worden het beste beoordeeld in verhouding tot de spreiding in de responswaarden, en niet aan een vaste grens.

De volledige pipeline werkt (inladen > train/test split > trainen > voorspellen > evalueren). De evaluatiematen zijn berekend en geïnterpreteerd. De resultaten laten zien dat er enige voorspellende waarde in de mutaties zit, en de cijfers zijn realistisch gezien de kleine dataset. De proof-of-principle is geslaagd.

Feature importance

[later toevoegen]

Bron in scikit-learn: User Guide → Supervised Learning → Regression Ensemble methods → RandomForestRegressor Metrics → Regression metrics

Chris wilt hier een reflectie op wat ik heb geleerd